

Predição da Energia de Docking de Peptídeos Utilizando Técnicas de Mineração de Dados e Aprendizado de Máquina

Amaury Walbert de Carvalho

Núcleo de Informática

Instituto Federal Goiano

Urutaí - GO, Brasil

amaury.carvalho@ifgoiano.edu.br

Leandro Nogueira Couto

Faculdade de Computação

Universidade Federal de Uberlândia

Uberlândia - MG, Brasil

leandronc@ufu.br

Murillo Guimarães Carneiro

Faculdade de Computação

Universidade Federal de Uberlândia

Uberlândia - MG, Brasil

mgarneiro@ufu.br

Resumo – A predição computacional da afinidade entre peptídeos e proteínas constitui uma etapa importante na descoberta de moléculas bioativas, permitindo reduzir o custo e o tempo associados às avaliações experimentais e às simulações de *docking* molecular. Neste trabalho foi desenvolvido um pipeline completo de Mineração de Dados aplicado à predição da energia de *docking* utilizando a base de dados SAGAPEP. Inicialmente foi realizada uma análise exploratória dos dados, incluindo pré-processamento, análise estatística e visualização das variáveis. Em seguida, foram implementados quatro descritores clássicos para representação de sequências peptídicas: Amino Acid Composition (AAC), Amino Acid Linking (AAL), Composition of k-Spaced Amino Acid Pairs (CKSNAP) e Composition of k-Spaced Amino Acid Group Pairs (CKSAAGP). Posteriormente, cinco algoritmos de regressão (Bayesian Ridge, Random Forest, Support Vector Regression, K-Nearest Neighbors e Multilayer Perceptron) foram treinados e avaliados utilizando validação cruzada K-Fold com dez partições, empregando as métricas RMSE, MAE, MSE e coeficiente de determinação (R^2). Os resultados demonstraram que a escolha da representação dos dados exerce influência significativa sobre o desempenho dos modelos de Aprendizado de Máquina. Entre os descritores avaliados, o CKSAAGP apresentou o melhor equilíbrio entre capacidade representacional e dimensionalidade, enquanto o algoritmo Random Forest obteve o melhor desempenho preditivo, alcançando RMSE de 13,79 e R^2 de 0,46. Os resultados evidenciam a importância da engenharia de atributos em aplicações de Mineração de Dados voltadas à Bioinformática e demonstram que representações biologicamente orientadas podem produzir modelos mais eficientes para a predição da energia de *docking*.

Palavras-chave – Mineração de Dados; Aprendizado de Máquina; Bioinformática; Docking Molecular; Peptídeos; Regressão; Engenharia de Atributos.

I. INTRODUÇÃO

A descoberta de novos peptídeos bioativos constitui uma das áreas de maior interesse da Bioinformática e da Química Medicinal, devido ao seu potencial para o desenvolvimento de novos fármacos, vacinas e terapias direcionadas. Uma das principais etapas desse processo consiste em avaliar a afinidade entre peptídeos e proteínas-alvo, geralmente estimada por meio de técnicas de docking molecular, que simulam computacionalmente a interação entre moléculas e fornecem uma estimativa da energia de ligação [1], [2].

Embora o docking molecular reduza significativamente os custos em relação aos experimentos laboratoriais, sua execução ainda demanda elevado poder computacional quando aplicada a grandes bibliotecas de peptídeos. Nesse contexto, técnicas de Mineração de Dados e Aprendizado de

Máquina têm sido utilizadas como uma alternativa para construir modelos capazes de estimar a energia de docking diretamente a partir da sequência de aminoácidos, reduzindo o número de moléculas que necessitam ser avaliadas por métodos computacionalmente mais custosos [3]-[5]. Essa estratégia constitui a base do framework SAGAPEP, que utiliza modelos preditivos para acelerar a avaliação de peptídeos bioativos.

Entretanto, algoritmos de Aprendizado de Máquina operam sobre atributos numéricos, tornando necessária a transformação das sequências biológicas em representações computacionais adequadas. Essa etapa, conhecida como engenharia de atributos (feature engineering), desempenha papel fundamental no desempenho dos modelos preditivos, pois diferentes descritores preservam diferentes níveis de informação sobre as características estruturais e físico-químicas dos peptídeos [6],[7].

Diversos descritores clássicos foram propostos para essa finalidade, entre os quais destacam-se o Amino Acid Composition (AAC), que representa a frequência dos aminoácidos na sequência [6]; o Amino Acid Linking (AAL), que considera pares consecutivos de resíduos [7]; o Composition of k-Spaced Amino Acid Pairs (CKSNAP), que incorpora pares separados por diferentes distâncias ao longo da sequência [7]; e o Composition of k-Spaced Amino Acid Group Pairs (CKSAAGP), que reduz a dimensionalidade da representação agrupando aminoácidos segundo suas propriedades físico-químicas [7]. Esses descritores vêm sendo empregados com sucesso em diferentes problemas de Bioinformática relacionados à classificação e predição de propriedades de proteínas e peptídeos.

Neste trabalho foi utilizada a base de dados SAGAPEP, composta por peptídeos previamente avaliados por docking molecular e anotados com seus respectivos valores de energia de interação. Essa base foi originalmente desenvolvida para apoiar a descoberta computacional de peptídeos com potencial de inibição da proteína Spike do SARS-CoV-2 e tem sido utilizada como referência para treinamento e avaliação de modelos preditivos baseados em aprendizado supervisionado [8,9].

A partir dessa base, foram aplicadas técnicas exploratórias de Mineração de Dados, incluindo pré-processamento, análise estatística e visualização dos dados, seguidas da implementação dos quatro descritores clássicos citados anteriormente.

Na etapa de modelagem foram avaliados cinco algoritmos de regressão amplamente utilizados em Aprendizado de Máquina: Bayesian Ridge, Random Forest,


Support Vector Regression (SVR), K-Nearest Neighbors (KNN) e Multilayer Perceptron (MLP), implementados por meio da biblioteca Scikit-learn [10]. Todos os modelos foram treinados utilizando validação cruzada K-Fold com dez partições, sendo avaliados por meio das métricas Root Mean Squared Error (RMSE), Mean Absolute Error (MAE), Mean Squared Error (MSE) e coeficiente de determinação (R^2), procedimento amplamente empregado para estimar a capacidade de generalização de modelos preditivos [11].

O objetivo deste trabalho é aplicar um pipeline completo de Mineração de Dados para a predição da energia de docking de peptídeos, desde a análise exploratória dos dados até a construção e avaliação de modelos de regressão, comparando diferentes estratégias de representação das sequências biológicas. Além de atender às etapas clássicas do processo de Mineração de Dados estudadas na disciplina, o trabalho busca analisar como a escolha dos descritores influencia o desempenho dos modelos preditivos em um problema real de Bioinformática.

II. MATERIAIS E MÉTODOS

Este trabalho foi desenvolvido seguindo as etapas clássicas de um processo de Mineração de Dados, compreendendo a seleção da base de dados, análise exploratória, engenharia de atributos, construção dos modelos preditivos e avaliação experimental [12]. A Figura 1 apresenta uma visão geral da metodologia empregada.

Fig. 1. Fluxograma da metodologia utilizada no projeto.



A. Base de Dados

Os experimentos foram realizados utilizando a base de dados SAGAPEP, proposta por Silva (2022) e posteriormente utilizada por Silva et al. (2024) para o desenvolvimento de um framework baseado em Algoritmo Genético Assistido por Surrogate voltado à descoberta de peptídeos com potencial de interação contra o SARS-CoV-2 [8], [9]. A base foi construída a partir de simulações de molecular docking, nas quais diferentes peptídeos foram avaliados quanto à sua afinidade com a proteína Spike do vírus.

O conjunto de dados é composto por 296 peptídeos e contém apenas duas colunas originais: a sequência de aminoácidos do peptídeo e a respectiva energia de docking, utilizada como variável resposta neste trabalho. Embora apresente apenas dois atributos, a base possui elevado conteúdo informacional, pois cada sequência biológica representa uma estrutura complexa que será posteriormente transformada em vetores numéricos por meio de técnicas de engenharia de atributos.

A Tabela I apresenta uma descrição dos atributos disponíveis na base.

TABLE I. DESCRIÇÃO DOS ATRIBUTOS DA BASE SAGAPEP.

Atributo	Tipo	Descrição
<i>peptide_fasta_sequence</i>	Texto	Sequência de aminoácidos representada segundo a notação FASTA, utilizando o código de uma letra para cada um dos vinte aminoácidos naturais.
<i>best_docking_score</i>	Numérico	Melhor energia de docking (kcal/mol) obtida para o peptídeo durante a simulação de interação com a proteína Spike. Corresponde à variável resposta utilizada nos modelos de regressão.

TABLE II. AMINOÁCIDOS REPRESENTADOS NA NOTAÇÃO FASTA.

Símbolo	Aminoácido	Símbolo	Aminoácido
A	Alanina	M	Metionina
C	Cisteína	N	Asparagina
D	Ácido Aspártico	P	Prolina
E	Ácido Glutâmico	Q	Glutamina
F	Fenilalanina	R	Arginina
G	Glicina	S	Serina
H	Histidina	T	Treonina
I	Isoleucina	V	Valina
K	Lisina	W	Triptofano
L	Leucina	Y	Tirosina

A coluna *peptide_fasta_sequence* contém a sequência primária de aminoácidos de cada peptídeo, representada pela notação FASTA de uma letra. Cada símbolo corresponde a um dos vinte aminoácidos naturais, conforme apresentado na Tabela II. Essas sequências constituem a informação biológica utilizada para gerar os descritores AAC, AAL, CKSNAP e CKSAAGP empregados na etapa de engenharia de atributos.

Por sua vez, a coluna *best_docking_score* representa a melhor energia de interação obtida entre cada peptídeo e a proteína-alvo durante as simulações de molecular docking. Essa medida é utilizada como indicador da afinidade

molecular prevista entre as moléculas, sendo que valores mais negativos indicam interações potencialmente mais estáveis. Dessa forma, o problema abordado neste trabalho consiste em uma tarefa de regressão supervisionada, cujo objetivo é estimar a energia de *docking* de novos peptídeos a partir de suas sequências de aminoácidos.

A Tabela III apresenta alguns registros representativos da base utilizada.

TABLE III. EXEMPLOS DE REGISTROS DA BASE SAGAPEP.

<i>peptide_fasta_sequence</i>	<i>best_docking_score</i>
PKVKMALRTSGHL	-177.914
GLGFDPEMQ	-164.233
PQTPLSTTGYLHTTPA	-202.362
ISSQLDKASIVRLSVTY	-158.362
IIITSLSDQIMEDSP	-151.936

Apesar de possuir apenas duas colunas, essa base não pode ser considerada de baixa dimensionalidade sob a perspectiva da Mineração de Dados. A informação contida na coluna *peptide_fasta_sequence* é altamente complexa e não pode ser utilizada diretamente pelos algoritmos de Aprendizado de Máquina. Por esse motivo, na etapa de engenharia de atributos cada sequência é convertida em vetores numéricos que representam diferentes aspectos da sua composição, organização e propriedades físico-químicas. Essa transformação amplia significativamente a dimensionalidade da base e permite a aplicação de algoritmos clássicos de regressão para a predição da energia de docking.

B. Análise Exploratória dos Dados

Antes da construção dos modelos de Aprendizado de Máquina foi realizada uma análise exploratória dos dados (Exploratory Data Analysis – EDA), com o objetivo de caracterizar estatisticamente a base SAGAPEP, identificar possíveis inconsistências e compreender o comportamento da variável resposta antes da etapa de modelagem.

Inicialmente foram calculadas medidas descritivas da variável *best_docking_score*, utilizada como variável resposta dos modelos de regressão. Os resultados encontram-se apresentados na Tabela IV.

TABLE IV. ESTATÍSTICAS DESCRITIVAS DA VARIÁVEL BEST_DOCKING_SCORE.


Estatística	Valor
Média	-175,98
Mediana	-176,11
Desvio padrão	19,34
Mínimo	-230,31
1º Quartil	-188,40
3º Quartil	-161,62
Máximo	-126,06

Observa-se que a energia de *docking* apresenta ampla variação, com valores compreendidos entre -230,31 e -126,06, indicando diferenças significativas na afinidade molecular prevista entre os peptídeos da base. A proximidade entre a média (-175,98) e a mediana (-176,11) sugere uma

distribuição aproximadamente simétrica, enquanto o desvio-padrão de 19,34 evidencia uma variabilidade moderada dos valores observados.

A distribuição da variável resposta foi investigada por meio do histograma e da estimativa de densidade (*Kernel Density Estimation – KDE*), apresentados na Figura 2.


Fig. 2. Distribuição da Energia de Docking



Visualmente, observa-se uma distribuição aproximadamente unimodal, sem evidências de assimetria acentuada ou da presença de múltiplos agrupamentos. A maior concentração das amostras ocorre entre aproximadamente -190 e -160, indicando que a maior parte dos peptídeos apresenta afinidade molecular intermediária dentro do conjunto analisado.

A Figura 3 apresenta o boxplot da variável resposta.

Fig. 3. Boxplot da Energia de Docking




Embora sejam observados alguns valores extremos, eles encontram-se distribuídos de forma consistente com a variabilidade biológica esperada para diferentes sequências peptídicas. Como não foram identificados indícios de erros de aquisição ou inconsistências nos dados, optou-se por manter todas as amostras durante os experimentos, preservando a diversidade da base de dados.

Para verificar formalmente a aderência da variável resposta à distribuição Normal foi aplicado o teste de Shapiro-Wilk, obtendo-se $W = 0,996$ e $p = 0,686$. Como o valor de $p > 0,05$, não foram encontradas evidências suficientes para rejeitar a hipótese de normalidade da distribuição.

Esse resultado é corroborado pelos coeficientes de assimetria (-0,170) e curtose (-0,075), ambos muito próximos de zero, indicando uma distribuição bastante semelhante à Normal. Essa observação também é corroborada pelo gráfico Quantil-Quantil (QQ Plot), apresentado na Figura 4. Essa característica é importante, pois sugere ausência de distorções


severas na variável resposta, favorecendo a estabilidade dos modelos de regressão avaliados posteriormente.

Fig. 4. QQ Plot da variável `best_docking_score`



Além da variável resposta, também foi analisado o comprimento das sequências peptídicas. A Figura 5 apresenta a distribuição do número de aminoácidos presentes em cada peptídeo da base.

Fig. 5. Distribuição do comprimento das sequências peptídicas.




Observa-se uma variabilidade moderada no tamanho das sequências, característica importante para avaliar a capacidade dos descritores em representar adequadamente peptídeos de diferentes comprimentos. Como os descritores utilizados neste trabalho baseiam-se em frequências relativas e relações entre aminoácidos, eles produzem vetores de tamanho fixo independentemente do comprimento da sequência, permitindo a utilização de algoritmos clássicos de Aprendizado de Máquina.

Também foi investigada a relação entre o comprimento das sequências peptídicas e a energia de docking. A análise de correlação indicou um coeficiente de Pearson igual a -0,422, caracterizando uma correlação negativa moderada. Isso indica que, em média, peptídeos mais longos tendem a


apresentar valores de energia de *docking* mais negativos, sugerindo maior afinidade molecular. Esses resultados podem ser observados na Figura 6. Entretanto, a dispersão observada no gráfico evidencia que o comprimento da sequência, isoladamente, não explica completamente a variabilidade da variável resposta, justificando a utilização de descritores capazes de incorporar informações sobre composição e organização estrutural dos aminoácidos.

Fig. 6. Comprimento do Peptídeo x Energia de Docking



Por fim, foi analisada a frequência global dos aminoácidos presentes em todas as sequências da base. Observou-se predominância dos resíduos prolina (P), com 945 ocorrências, seguida por glicina (G) (601), serina (S) (402), alanina (A) (348) e leucina (L) (276). Aminoácidos como valina, lisina, treonina, arginina e ácido glutâmico também apresentaram frequências expressivas. A elevada ocorrência desses resíduos sugere que propriedades relacionadas à flexibilidade conformacional, hidrofobicidade e interações eletrostáticas podem desempenhar papel relevante na afinidade molecular dos peptídeos, reforçando a importância de descritores que incorporem propriedades físico-químicas durante a etapa de engenharia de atributos. A Figura 07 apresenta o histograma com a frequência global dos aminoácidos.

Fig. 7. Frequência Global dos Aminoácidos



De forma geral, a análise exploratória permitiu caracterizar adequadamente a base SAGAPEP e confirmou sua consistência para aplicação das técnicas de Mineração de Dados propostas neste trabalho. Os resultados obtidos indicam que a variável resposta apresenta comportamento estatístico adequado para a modelagem, ao mesmo tempo em que evidenciam que características simples, como o comprimento da sequência, não são suficientes para explicar completamente a energia de *docking*. Essa constatação

reforça a necessidade da etapa de engenharia de atributos, apresentada na seção seguinte, na qual são exploradas diferentes representações das sequências peptídicas visando melhorar a capacidade preditiva dos modelos de Aprendizado de Máquina.

Como o artigo possui limitação de espaço, as demais visualizações produzidas durante a análise exploratória são apresentadas apenas nos notebooks desenvolvidos para o projeto.

C. Engenharia de Atributos

Como algoritmos de Aprendizado de Máquina operam sobre atributos numéricos, foi necessária a transformação das sequências de aminoácidos em vetores de características. Para isso foram implementados quatro descritores clássicos amplamente utilizados em Bioinformática.

O descritor AAC (*Amino Acid Composition*) representa cada sequência pela frequência relativa dos vinte aminoácidos naturais, produzindo vetores compostos por 20 atributos.

O descritor AAL (*Amino Acid Linking*) amplia essa representação contabilizando pares consecutivos de aminoácidos, resultando em 400 atributos.

O descritor CKSNAP (*Composition of k-Spaced Amino Acid Pairs*) considera pares de aminoácidos separados por diferentes distâncias ao longo da sequência. Neste trabalho foram utilizados os valores de $k=0$ a $k=5$, produzindo uma representação composta por 2.400 atributos.

Por fim, foi implementado o descritor CKSAAGP (*Composition of k-Spaced Amino Acid Group Pairs*), que agrupa aminoácidos segundo suas propriedades físico-químicas e contabiliza pares de grupos separados por diferentes distâncias. Essa estratégia reduz a dimensionalidade da representação para apenas 150 atributos, preservando informações estruturais relevantes.

A Tabela V resume as principais características dos descritores implementados.

TABLE V. COMPARAÇÃO DOS DESCRITORES UTILIZADOS NO TRABALHO.

Descritor	Informação representada	Nº de atributos
AAC	Frequência dos aminoácidos	20
AAL	Pares consecutivos	400
CKSNAP	Pares separados por distância k	2.400
CKSAAGP	Pares de grupos bioquímicos	150

D. Modelos de Regressão

Após a etapa de engenharia de atributos, foram avaliados cinco algoritmos clássicos de Aprendizado de Máquina para problemas de regressão: Bayesian Ridge, Random Forest, Support Vector Regression (SVR), K-Nearest Neighbors (KNN) e Multilayer Perceptron (MLP). A seleção desses modelos buscou contemplar diferentes paradigmas de aprendizado supervisionado, permitindo avaliar o impacto dos descritores em algoritmos com características distintas.

O Bayesian Ridge foi escolhido por representar um modelo linear probabilístico com regularização automática, sendo utilizado como referência (baseline) para comparação com métodos não lineares. O Random Forest foi selecionado devido à sua elevada capacidade de modelar relações não lineares, robustez à presença de atributos irrelevantes e bom desempenho em conjuntos de dados de média dimensão. O Support Vector Regression (SVR) foi incluído por sua reconhecida eficiência em problemas de regressão envolvendo espaços de alta dimensionalidade, enquanto o K-Nearest Neighbors (KNN) representa os métodos baseados em instâncias, permitindo avaliar diretamente a influência da similaridade entre amostras. Por fim, a Multilayer Perceptron (MLP) foi empregada para investigar a capacidade de uma rede neural artificial em modelar relações não lineares presentes nos dados.

Como o objetivo deste trabalho consiste em comparar o impacto dos diferentes descritores sobre o desempenho dos modelos, optou-se por utilizar configurações iniciais (baseline) amplamente adotadas na literatura, evitando procedimentos de otimização de hiperparâmetros que poderiam introduzir viés na comparação entre as representações. Dessa forma, buscou-se manter condições experimentais equivalentes para todos os modelos, permitindo que as diferenças observadas fossem atribuídas predominantemente à qualidade dos descritores.

Para o Bayesian Ridge, foram utilizados hiperparâmetros pouco informativos, permitindo que o próprio algoritmo estimasse automaticamente os parâmetros de regularização durante o treinamento. O Random Forest foi configurado com 200 árvores ($n_estimators = 200$), aumentando a estabilidade das previsões em relação à configuração padrão, sem limitar a profundidade máxima das árvores ($max_depth = None$). No SVR, foi adotado o kernel radial (RBF) com os parâmetros $C=1,0$ $\epsilon=0,1$ $\gamma = scale$, configuração amplamente empregada em problemas de regressão não linear. O KNN foi configurado com cinco vizinhos mais próximos ($k=5$) e distância Euclidiana, representando uma configuração clássica para problemas supervisionados. Já a MLP foi implementada com uma única camada oculta contendo 100 neurônios, função de ativação ReLU, algoritmo de otimização Adam e limite máximo de 1000 épocas, buscando equilibrar capacidade de modelagem e custo computacional para a dimensão da base utilizada.

A Tabela VI apresenta os principais hiperparâmetros adotados em cada algoritmo.

TABLE VI. ALGORITMOS DE REGRESSÃO E HIPERPARÂMETROS UTILIZADOS.

Algoritmo	Principais hiperparâmetros
Bayesian Ridge	$\alpha_1 = \alpha_2 = \lambda_1 = \lambda_2 = 10^{-6}$
Random Forest	$n_estimators = 200$, $max_depth = None$, $bootstrap = True$
SVR	$kernel = RBF$, $C=1,0$, $\epsilon = 0,1$, $\gamma = scale$
KNN	$k = 5$, distância Euclidiana
MLP	100 neurônios, ReLU, Adam, $max_iter = 1000$

E. Avaliação Experimental

Todos os modelos foram implementados utilizando a biblioteca Scikit-learn [10] e avaliados utilizando validação cruzada K-Fold com dez partições, garantindo que cada amostra fosse utilizada tanto para treinamento quanto para teste ao longo dos experimentos.

O desempenho dos modelos foi avaliado por meio das seguintes métricas:

- Root Mean Squared Error (RMSE);
- Mean Absolute Error (MAE);
- Mean Squared Error (MSE);
- Coeficiente de determinação (R^2).

A utilização simultânea dessas métricas permite avaliar diferentes aspectos da qualidade das predições, incluindo magnitude dos erros, estabilidade dos modelos e capacidade de explicação da variabilidade da variável resposta.

III. RESULTADOS E DISCUSSÃO

A. Comparação dos Descritores

Após a implementação dos descritores AAC, AAL, CKSNAP e CKSAAGP, foi realizada uma análise comparativa com o objetivo de avaliar sua capacidade de representar as sequências peptídicas da base SAGAPEP antes da etapa de treinamento dos modelos de regressão. Para essa avaliação foram considerados aspectos relacionados à dimensionalidade, variabilidade dos atributos, capacidade de representação dos dados e relevância das características extraídas.

A Tabela VII apresenta uma comparação inicial entre os quatro descritores implementados.

Observa-se inicialmente uma diferença significativa na dimensionalidade das representações. Enquanto o descritor AAC produz apenas 20 atributos correspondentes à frequência relativa dos aminoácidos, o CKSNAP gera um espaço de características composto por 2.400 atributos, resultado da contabilização de pares de aminoácidos separados por diferentes distâncias ao longo da sequência. O AAL apresenta uma representação intermediária, composta por 400 atributos, enquanto o CKSAAGP reduz essa dimensionalidade para apenas 150 atributos ao agrupar aminoácidos segundo suas propriedades físico-químicas.

TABLE VII. COMPARAÇÃO GERAL ENTRE OS DESCRITORES IMPLEMENTADOS.

Descritor	Nº de atributos	Variância média	PCA (PC1 + PC2)
AAC	20	0,005424	19,14%
AAL	400	0,000270	2,77%
CKSNAP	2400	0,000332	2,23%
CKSAAGP	150	0,005117	16,51%

O crescimento da dimensionalidade é acompanhado por uma redução da variância média dos atributos. Enquanto AAC e CKSAAGP apresentam variâncias médias próximas de 0,005, os descritores AAL e CKSNAP apresentam valores próximos de 0,0003, indicando que a informação encontra-se distribuída entre um número muito maior de atributos.

Para avaliar a capacidade de representação dos dados foi aplicada a Análise de Componentes Principais (PCA), calculando-se a porcentagem de variância explicada pelas duas primeiras componentes principais. Os resultados mostram que o AAC concentrou aproximadamente 19,14% da variabilidade dos dados, seguido pelo CKSAAGP, com 16,51%. Em contraste, os descritores AAL e CKSNAP apresentaram valores significativamente inferiores, de 2,77% e 2,23%, respectivamente.

Esse comportamento pode ser explicado pela elevada dimensionalidade dessas representações. À medida que novos atributos são incorporados, a informação tende a distribuir-se entre um número maior de dimensões, reduzindo a capacidade das primeiras componentes principais em representar a variabilidade total dos dados.

Além da análise de dimensionalidade, foi investigada a relevância dos atributos utilizando duas medidas complementares: Informação Mútua (Mutual Information - MI) e correlação de Pearson com a variável resposta.

A Tabela VIII apresenta uma comparação normalizada dessas métricas entre os descritores.

TABLE VIII. COMPARAÇÃO NORMALIZADA DOS DESCRITORES.

Descritor	Dimensionalidade	PC A	MI	Correlação
AAC	0,000	1,00 0	1,00 0	1,000
AAL	0,160	0,03 2	0,04 8	0,019
CKSNAP	1,000	0,00 0	0,00 0	0,000
CKSAA GP	0,055	0,84 4	0,93 6	0,868


A análise integrada evidencia diferenças importantes entre as estratégias de representação. O AAC apresentou os melhores resultados em termos de concentração da variabilidade e associação direta com a variável resposta, consequência da baixa dimensionalidade da representação. Entretanto, esse descritor considera apenas a composição global dos aminoácidos, ignorando completamente sua organização ao longo da sequência.

O AAL e o CKSNAP, por outro lado, incorporam informações estruturais relacionadas à posição relativa dos aminoácidos. Apesar desse ganho representacional, ambos produziram espaços de atributos altamente dimensionais, nos quais a informação ficou distribuída entre centenas ou milhares de características, reduzindo os valores de variância explicada, Informação Mútua e correlação média.

O CKSAAGP apresentou o comportamento mais equilibrado entre os descritores avaliados. Embora utilize apenas 150 atributos, sua capacidade representacional aproximou-se daquela observada para o AAC, ao mesmo tempo em que preserva informações estruturais inexistentes na composição simples dos aminoácidos. Esse resultado sugere que o agrupamento dos resíduos segundo propriedades físico-químicas reduz a complexidade da representação sem comprometer significativamente a informação disponível para os modelos de Aprendizado de Máquina.

A Figura 8 resume a comparação integrada entre os quatro descritores considerando todas as métricas analisadas.

Fig. 8. Comparação integrada dos descritores (Dimensionalidade, PCA, Informação Mútua e Correlação).



De forma geral, os resultados indicam que o aumento da dimensionalidade não implica necessariamente maior capacidade de representação dos dados. Embora o CKSNAP produza o conjunto de atributos mais detalhado, essa riqueza descritiva encontra-se distribuída entre um grande número de variáveis, dificultando sua exploração pelos algoritmos de regressão. Em contraste, o CKSAAGP demonstrou representar um compromisso mais adequado entre complexidade e capacidade representacional, preservando informações relevantes sobre as sequências sem gerar espaços excessivamente dimensionais.

Essas observações justificam a etapa seguinte do trabalho, na qual os quatro descritores foram utilizados como entrada para diferentes algoritmos de regressão, permitindo avaliar de que forma suas características influenciam efetivamente o desempenho preditivo dos modelos.

B. Avaliação dos Modelos de Regressão

Ao todo foram avaliadas 20 configurações experimentais, resultantes da combinação entre os quatro descritores e os cinco algoritmos de regressão. O desempenho dos modelos foi analisado por meio das métricas RMSE, MAE, MSE e coeficiente de determinação (R^2), sendo considerados como melhores modelos aqueles que apresentaram menores valores de erro e maiores valores de R^2 .

O desempenho dos modelos variou significativamente em função da representação utilizada, evidenciando que a qualidade dos atributos exerce influência direta sobre a capacidade preditiva dos algoritmos de Aprendizado de Máquina.


A Figura 9 apresenta a comparação dos valores médios de RMSE obtidos pelos diferentes modelos.

Verifica-se que o algoritmo Random Forest apresentou os menores valores de RMSE para praticamente todos os descritores avaliados. O melhor resultado foi obtido utilizando o descritor CKSAAGP, alcançando RMSE igual a 13,79, seguido pela combinação AAC + Random Forest, com desempenho bastante próximo.

Os algoritmos Bayesian Ridge e SVR apresentaram desempenho intermediário, mantendo comportamento


relativamente estável independentemente do descritor utilizado. O KNN apresentou desempenho inferior aos modelos anteriores, indicando maior sensibilidade à forma de representação dos dados. Já a MLP obteve os maiores erros de predição na maioria dos experimentos, sugerindo que a quantidade de amostras disponível pode não ser suficiente para explorar plenamente o potencial de uma rede neural artificial.

Fig. 9. Comparação dos valores de RMSE para cada descritor.




A Figura 10 apresenta os valores do coeficiente de determinação (R^2) obtidos pelos modelos.

Fig. 10. Comparação dos valores de R^2 dos modelos de regressão.



Para facilitar a comparação entre todas as configurações experimentais, a Figura 11 apresenta um mapa de calor (heatmap) contendo os valores de RMSE obtidos para cada combinação entre descritor e algoritmo.

Fig. 11. Heatmap dos valores de RMSE obtidos pelos modelos.



Embora esse valor não represente um ajuste perfeito, trata-se de um resultado expressivo considerando a elevada complexidade do problema biológico, a pequena dimensão da base de dados e o fato de que apenas informações derivadas


da sequência primária dos peptídeos foram utilizadas como entrada para os modelos.

O heatmap evidencia dois comportamentos importantes. Primeiramente, observa-se que o Random Forest apresentou desempenho consistente independentemente do descritor empregado, indicando elevada robustez frente a diferentes espaços de atributos. Em segundo lugar, percebe-se que o CKSAAGP produziu resultados competitivos para praticamente todos os algoritmos, sugerindo que essa representação preserva informações relevantes para diferentes paradigmas de aprendizado supervisionado.

Por fim, a Figura 12 apresenta o ranking das melhores configurações experimentais.

Os resultados demonstram que as duas primeiras posições foram ocupadas por modelos baseados em Random Forest, utilizando os descritores CKSAAGP e AAC, respectivamente. Esse comportamento reforça a capacidade desse algoritmo em explorar relações não lineares presentes nas representações extraídas das sequências biológicas.

Fig. 12. Ranking das cinco melhores combinações entre descritores e algoritmos.



Além disso, observa-se que descritores de elevada dimensionalidade, como o CKSNAP, não apresentaram desempenho superior às representações mais compactas. Esse resultado confirma uma das hipóteses levantadas durante a etapa de engenharia de atributos: o aumento do número de características não implica, necessariamente, melhoria da capacidade preditiva dos modelos.

De maneira geral, os experimentos evidenciam que o desempenho dos algoritmos depende tanto da estratégia de representação das sequências quanto da capacidade do modelo em explorar relações complexas entre os atributos. Entre todas as configurações avaliadas, a combinação CKSAAGP + Random Forest apresentou o melhor equilíbrio entre capacidade representacional e desempenho preditivo, constituindo a melhor solução encontrada para a base SAGAPEP.

C. Discussão Integrada

Os resultados obtidos ao longo deste trabalho evidenciam a forte influência da etapa de engenharia de atributos sobre o desempenho dos modelos de Aprendizado de Máquina. Embora todos os algoritmos tenham sido treinados utilizando exatamente o mesmo protocolo experimental e os mesmos hiperparâmetros, diferenças significativas foram observadas em função da representação utilizada para descrever as sequências peptídicas.

Uma primeira observação importante refere-se à relação entre dimensionalidade e capacidade preditiva. Intuitivamente, poderia-se esperar que descritores contendo

maior quantidade de informações produzissem modelos mais precisos. Entretanto, os resultados mostraram que essa relação não é necessariamente verdadeira. O descritor CKSNAP, responsável pela geração do maior conjunto de atributos (2.400 variáveis), não apresentou o melhor desempenho nos experimentos, sendo superado por representações significativamente mais compactas.

Esse comportamento pode ser explicado pela chamada maldição da dimensionalidade (*curse of dimensionality*), fenômeno amplamente discutido na literatura de Mineração de Dados [3]. À medida que o número de atributos aumenta, os dados tornam-se mais esparsos e a informação tende a distribuir-se entre muitas dimensões, dificultando a identificação de padrões pelos algoritmos de aprendizado. Esse efeito foi evidenciado pela baixa porcentagem de variância explicada obtida pelo CKSNAP na análise por Componentes Principais, indicando que a informação encontra-se dispersa em um grande número de atributos.

Em contraste, o descritor CKSAAGP apresentou um comportamento bastante distinto. Apesar de utilizar apenas 150 atributos, sua representação preservou grande parte das informações relevantes das sequências, alcançando valores elevados de variância explicada, Informação Mútua e correlação com a variável resposta. Esse resultado demonstra que o agrupamento dos aminoácidos segundo propriedades físico-químicas constitui uma estratégia eficiente para reduzir a dimensionalidade sem comprometer significativamente a capacidade representacional.

Outro aspecto observado refere-se ao impacto da representação sobre os diferentes paradigmas de aprendizado supervisionado. O algoritmo Random Forest apresentou desempenho superior para praticamente todos os descritores avaliados, demonstrando elevada robustez frente a diferentes espaços de atributos. Esse comportamento pode ser atribuído à natureza do algoritmo, baseado na combinação de múltiplas árvores de decisão, capaz de modelar relações não lineares e lidar naturalmente com atributos redundantes ou pouco informativos.

Por outro lado, modelos como Bayesian Ridge apresentaram desempenho competitivo apenas para descritores de menor dimensionalidade, comportamento esperado em modelos lineares. Da mesma forma, o KNN mostrou-se sensível ao aumento da dimensionalidade dos dados, uma vez que métodos baseados em distância tendem a perder eficiência em espaços de muitas dimensões. A MLP, embora possua elevada capacidade de modelagem, apresentou desempenho inferior ao esperado, possivelmente em função do reduzido número de amostras disponíveis para treinamento. Redes neurais artificiais geralmente requerem conjuntos de dados maiores para estimar adequadamente seus parâmetros e evitar problemas de sobreajuste.

Os resultados também reforçam a importância da engenharia de atributos dentro do processo de Mineração de Dados. Em diversos experimentos, a alteração da representação produziu diferenças mais significativas no desempenho dos modelos do que a própria substituição do algoritmo de regressão. Essa observação evidencia que a qualidade dos atributos utilizados como entrada exerce papel decisivo na construção de modelos preditivos, aspecto frequentemente destacado na literatura da área [3], [4].

Do ponto de vista da Bioinformática, os experimentos demonstraram que representações baseadas apenas na

composição global dos aminoácidos, como o AAC, já fornecem informações relevantes para a predição da energia de docking. Entretanto, a incorporação de informações estruturais e propriedades físico-químicas, realizada pelo CKSAAGP, permitiu melhorar a capacidade de representação das sequências sem provocar crescimento excessivo da dimensionalidade. Esse resultado sugere que descritores capazes de combinar composição, organização local e características bioquímicas apresentam maior potencial para aplicações envolvendo predição de propriedades de peptídeos.

Finalmente, deve-se destacar algumas limitações deste estudo. A base SAGAPEP contém 296 peptídeos, número relativamente pequeno quando comparado a conjuntos de dados utilizados em aplicações modernas de Aprendizado de Máquina. Além disso, apenas descritores derivados da sequência primária dos peptídeos foram considerados, desconsiderando informações tridimensionais, conformacionais ou provenientes de modelos recentes de aprendizado profundo para proteínas. Essas limitações provavelmente restringem o desempenho máximo alcançável pelos modelos avaliados.

Apesar dessas limitações, o trabalho atingiu plenamente seus objetivos ao implementar todas as etapas clássicas de um processo de Mineração de Dados, desde a análise exploratória até a avaliação dos modelos preditivos. Além disso, a implementação manual dos descritores possibilitou compreender em profundidade como diferentes estratégias de representação influenciam o desempenho dos algoritmos de Aprendizado de Máquina, contribuindo para uma análise mais abrangente da relação entre engenharia de atributos e modelagem preditiva aplicada à Bioinformática.

A Tabela IX reúne a síntese dos principais resultados obtidos.

TABLE IX. SÍNTESE DOS PRINCIPAIS RESULTADOS DO TRABALHO.

Aspecto avaliado	Principal resultado
Melhor descritor	CKSAAGP
Melhor algoritmo	Random Forest
Melhor combinação	CKSAAGP + Random Forest
Menor RMSE	13,79
Maior R^2	0,460
Principal conclusão	A qualidade da representação dos dados exerce maior influência no desempenho dos modelos do que o simples aumento da dimensionalidade.

IV. CONCLUSÃO

Neste trabalho foi desenvolvido um pipeline completo de Mineração de Dados aplicado à predição da energia de docking de peptídeos utilizando a base de dados SAGAPEP. O projeto contemplou todas as etapas clássicas do processo de descoberta de conhecimento, incluindo análise exploratória dos dados, engenharia de atributos, construção de modelos preditivos e avaliação dos resultados obtidos.

Na etapa de análise exploratória foi possível caracterizar estatisticamente a base de dados, compreender a distribuição da variável resposta e identificar padrões relacionados à composição das sequências peptídicas. Essas análises forneceram subsídios para a etapa seguinte de engenharia de atributos, na qual foram implementados quatro descritores clássicos amplamente utilizados em Bioinformática: AAC, AAL, CKSNAP e CKSAAGP.

A comparação entre os descritores evidenciou que diferentes estratégias de representação produzem espaços de características com propriedades bastante distintas. Enquanto o AAC apresentou uma representação compacta baseada apenas na composição global das sequências, o AAL e o CKSNAP incorporaram informações estruturais ao custo de um aumento significativo da dimensionalidade. O CKSAAGP, por sua vez, apresentou o melhor equilíbrio entre riqueza representacional e número de atributos, preservando informações relevantes ao agrupar os aminoácidos segundo suas propriedades físico-químicas.

Na etapa de modelagem foram avaliados cinco algoritmos clássicos de regressão utilizando validação cruzada K-Fold com dez partições. Os resultados demonstraram que o desempenho dos modelos depende fortemente da representação utilizada, confirmando a importância da etapa de engenharia de atributos em problemas de Aprendizado de Máquina aplicados à Bioinformática.

Entre todas as combinações avaliadas, a utilização do descritor CKSAAGP em conjunto com o algoritmo Random Forest apresentou o melhor desempenho, obtendo os menores valores de erro e o maior coeficiente de determinação entre os modelos analisados. Esse resultado indica que a utilização de grupos de aminoácidos definidos por propriedades físico-químicas constitui uma estratégia eficiente para representar sequências peptídicas em tarefas de regressão.

De forma geral, os experimentos mostraram que o aumento da dimensionalidade não implica, necessariamente, melhoria da capacidade preditiva dos modelos. Representações excessivamente detalhadas, como o CKSNAP, distribuíram a informação entre um grande número de atributos, enquanto representações mais compactas e biologicamente orientadas apresentaram melhor capacidade de generalização.

Além de atender aos objetivos propostos para a disciplina de Mineração de Dados, este trabalho permitiu consolidar conhecimentos relacionados às etapas de preparação dos dados, extração de características, treinamento de modelos supervisionados e avaliação de desempenho. A implementação manual dos descritores também contribuiu para uma compreensão mais aprofundada das técnicas clássicas utilizadas na representação de sequências biológicas.

Como continuidade deste estudo, pretende-se investigar estratégias de seleção automática de atributos, otimização de hiperparâmetros e descritores baseados em modelos recentes de aprendizado profundo para proteínas, bem como ampliar a avaliação utilizando bases de dados contendo maior número de peptídeos e diferentes proteínas-alvo.

DISPONIBILIDADE DO CÓDIGO E DOS DADOS

Com o objetivo de garantir a reprodutibilidade dos experimentos e disponibilizar todo o material desenvolvido

durante a disciplina, os notebooks Jupyter utilizados neste trabalho, a base de dados SAGAPEP empregada nos experimentos, os descritores implementados, os resultados completos das análises exploratórias, os gráficos produzidos, os resultados dos modelos de regressão e demais comentários e documentações do projeto encontram-se disponíveis em um repositório público no GitHub, acessível pelo endereço:

<https://github.com/amaurywalbert/projeto-mineracao>

O repositório contém a organização completa do projeto, incluindo os notebooks referentes às etapas de análise exploratória dos dados, implementação dos descritores (AAC, AAL, CKSNAP e CKSAAGP), treinamento dos modelos de Aprendizado de Máquina, arquivos de dados processados, figuras utilizadas no artigo e demais resultados obtidos durante o desenvolvimento do trabalho.

AGRADECIMENTOS

Os autores agradecem ao Programa de Pós-Graduação em Ciência da Computação da Universidade Federal de Uberlândia (UFU) pela oferta da disciplina de Mineração de Dados, que motivou o desenvolvimento deste projeto, e ao Instituto Federal Goiano pelo apoio às atividades de pesquisa e capacitação docente.

REFERENCES

- [1] D. B. Kitchen, H. Decornez, J. R. Furr and J. Bajorath, "Docking and scoring in virtual screening for drug discovery: methods and applications," *Nature Reviews Drug Discovery*, vol. 3, no. 11, pp. 935–949, 2004.
- [2] X.-Y. Meng, H.-X. Zhang, M. Mezei and M. Cui, "Molecular docking: a powerful approach for structure-based drug discovery," *Current Computer-Aided Drug Design*, vol. 7, no. 2, pp. 146–157, 2011.
- [3] J. Han, M. Kamber and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Burlington, MA, USA: Morgan Kaufmann, 2012.
- [4] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006.
- [5] S. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 3rd ed. Upper Saddle River, NJ, USA: Pearson, 2013.
- [6] H. Nakashima and K. Nishikawa, "Discrimination of intracellular and extracellular proteins using amino acid composition and residue-pair frequencies," *Journal of Molecular Biology*, vol. 238, no. 1, pp. 54–61, 1994.
- [7] Z. Chen, P. Zhao, F. Li, J. T. Leier, L. A. Marquez-Lago, Y. Wang, G. I. Webb and A. I. Smith, "iFeature: a Python package and web server for features extraction and selection from protein and peptide sequences," *Bioinformatics*, vol. 34, no. 14, pp. 2499–2502, 2018.
- [8] E. A. D. Silva, *Algoritmo Genético Assistido por Surrogate para Avaliar e Descobrir Peptídeos contra o SARS-CoV-2*. Dissertação (Mestrado em Ciência da Computação), Universidade Federal de Uberlândia, Uberlândia, Brasil, 2022.
- [9] E. A. D. Silva, L. S. Palmeira, M. A. Garcia-Junior, L. G. A. Martins, Y. Jin, B. S. Andrade, R. Sabino-Silva and M. G. Carneiro, "A Surrogate-Assisted Genetic Algorithm Framework to Discover Peptides against COVID-19 Virus," in *Proceedings of the IEEE Congress on Evolutionary Computation (CEC)*, Yokohama, Japan, 2024, pp. 1–8, doi: 10.1109/CEC60901.2024.10611783.
- [10] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [11] R. Kohavi, "A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection," *Proceedings of the Fourteenth International Joint Conference on Artificial Intelligence (IJCAI)*, pp. 1137–1143, 1995.
- [12] I. H. Witten, E. Frank, M. A. Hall and C. J. Pal, *Data Mining: Practical Machine Learning Tools and Techniques*, 4th ed. Burlington, MA, USA: Morgan Kaufmann, 2016.